Portafolio de Competencias en IA

Certificación · Corte 3 · Principios de Inteligencia Artificial 2026-B

Estudiante: Andrés Felipe Bolívar Arias
Programa: Ingeniería en Inteligencia Artificial, CORHUILA
Repositorio: github.com/anfebolivar2-lab/principios-ia-2026-b-g1

Sección	Contenido
1	Reflexión de aprendizaje
2	Los 3 mejores artefactos del semestre (uno por corte) y por qué los elegí
3	Mapa de competencias con autoevaluación y evidencia
4	Próximos pasos

Nota de transparencia. Este portafolio se redactó con ayuda de una IA (Claude) a partir de los trabajos reales del repositorio. Todos los números y capturas salen de ejecutar los trabajos. El artefacto del Corte 2 (proyecto de ML) no existía en el repositorio y fue construido con esa misma ayuda; está declarado así en su propio README.

1. Reflexión de aprendizaje

El concepto más difícil: saber si un modelo realmente funciona

Lo más difícil no fue entrenar modelos, sino **decidir si se puede confiar en ellos**. Entrenar es fácil: en Teachable Machine bastaron 40 fotos por clase y un botón. Lo difícil es interpretar lo que sale. Ese modelo acertó las 10 fotos de prueba con 100 % de confianza, pero su validación interna daba solo 0.83 para la clase Gato, con apenas 6 fotos por clase. Dos números que parecen contradecirse en realidad cuentan lo mismo: con tan pocos datos no sé cuánto vale el modelo. En el proyecto de ML pasó algo parecido: el árbol de decisión llegaba a 100 % de exactitud en entrenamiento (profundidad 8) y bajaba a 92 % en prueba. Es overfitting, y sin separar los datos lo habría tomado por un modelo perfecto.

El concepto más revelador: los modelos fallan con seguridad

Lo que más cambió mi visión fue ver un modelo equivocarse sin dudar. En Hugging Face, el modelo de sentimiento XLM-RoBERTa clasificó "Qué belleza, otra vez se fue la luz" como **positivo con 0.846 de confianza**, cuando es una queja sarcástica. Acertó la jerga colombiana ("una chimba", 0.937) y falló con la ironía. Entendí que el número de confianza de un modelo **no es una garantía de acierto**, y que los sesgos de los datos de entrenamiento (tweets de muchos idiomas, poco español colombiano e ironía) se heredan en silencio cuando uno solo usa el modelo ya entrenado.

Cómo cambió mi visión de la IA

Empecé el curso con la idea de que la IA es "un modelo que aprende de datos". El semestre me mostró dos cosas más. Primero, que **la IA clásica de búsqueda sigue siendo muy potente**: en el 8-puzzle más difícil, A* con la heurística Manhattan expandió 906 nodos contra 115 310 de BFS, con la misma solución óptima. No hizo falta ningún dato. Segundo, que **evaluar y cuestionar** un modelo es tan importante como construirlo: la matriz de confusión, la validación cruzada y las pruebas con casos difíciles son las que separan una demo vistosa de un sistema en el que se puede confiar.

2. Los 3 mejores artefactos del semestre

Corte 1 · Agente de búsqueda: A* vs BFS vs UCS en el 8-puzzle

Dónde está: `04-week/03-optional-activity/semana4-busqueda-informada/`

Por qué lo elegí: es el trabajo donde mejor se ve una idea completa de principio a fin: formular un problema como espacio de estados, diseñar una heurística admisible y **medir** el efecto con datos. La heurística Manhattan es admisible (nunca sobreestima) y consistente, y los resultados lo confirman: los tres algoritmos hallan la solución óptima, pero A* explora una fracción de los nodos.

```
def manhattan_distance(state, goal_pos=_GOAL_POS) -> int:
    total = 0
    for index, value in enumerate(state):
        if value == 0:
            continue
        r, c = divmod(index, 3)
        gr, gc = goal_pos[value]
        total += abs(r - gr) + abs(c - gc)
    return total
```

Instancia (muy difícil)	Movimientos	Nodos expandidos	Tiempo (s)
BFS	24	115 310	0.502
UCS	24	139 315	0.979
A*	24	**906**	**0.0099**

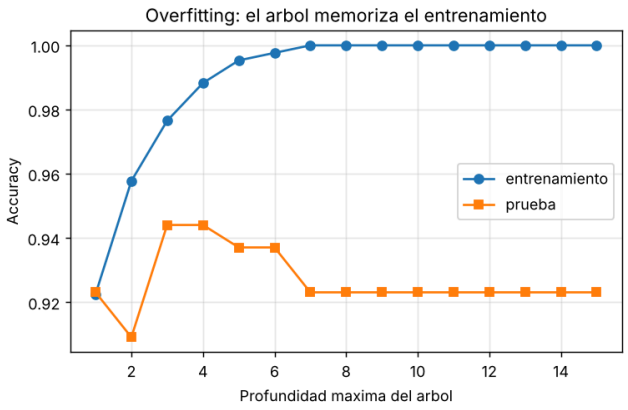
Fuente: results.md del trabajo. Los tres algoritmos devuelven la misma solución óptima de 24 movimientos.

Corte 2 · Aprendizaje automático: clasificación de tumores con validación y análisis de overfitting

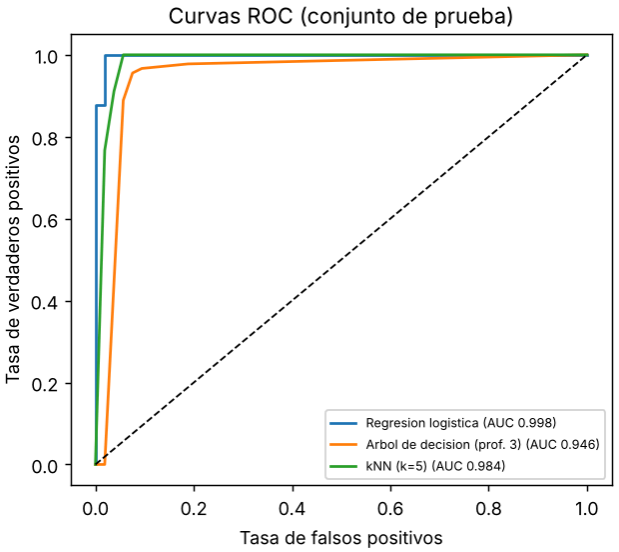
Dónde está: `08-week/proyecto-ml-cancer/` (*construido con ayuda de IA, ver nota de transparencia*)

Por qué lo elegí: reúne lo que se pide de un buen proyecto de ML: tres modelos comparados con validación cruzada, matriz de confusión, curva ROC y una demostración visual del overfitting. El resultado más útil no es el modelo ganador, sino el análisis: en diagnóstico el error caro es el **falso negativo**, y la regresión logística cometió 1 en 143 casos.

Modelo	CV 5-fold	Accuracy test	AUC test
Regresión logística	0.979 ± 0.009	0.986	0.998
Árbol (prof. 3)	0.939 ± 0.022	0.944	0.946
kNN (k=5)	0.967 ± 0.014	0.979	0.984



El árbol llega a 100 % en entrenamiento y se queda en ~92 % en prueba.

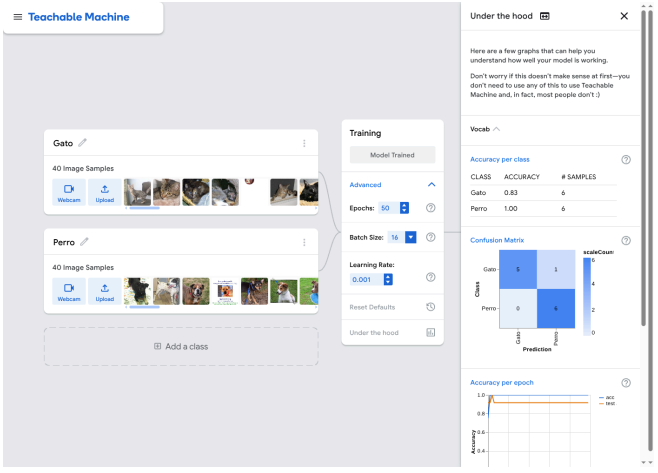


Curvas ROC en el conjunto de prueba.

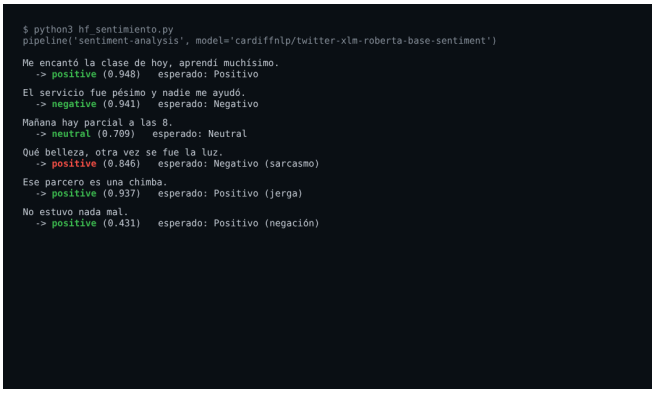
Corte 3 · Comparación de herramientas de IA: Teachable Machine vs Hugging Face

Dónde está: `14-week/actividad-herramientas-ia/`

Por qué lo elegí: es el único artefacto que contrasta dos formas de hacer IA (entrenar un modelo propio con *transfer learning* frente a usar uno *pre-entrenado* para hacer *inference*) y que termina en una **reflexión ética basada en un fallo observado**, no en teoría. Incluye el modelo exportado y 11 capturas del proceso.



Teachable Machine: precisión por clase (Gato 0.83, Perro 1.00) y matriz de confusión.

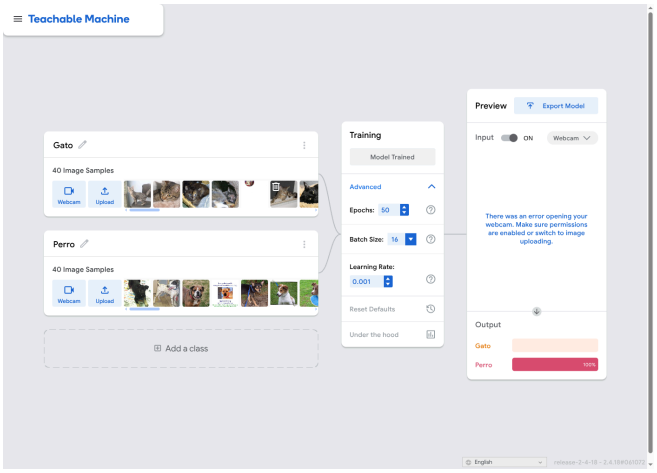


Hugging Face: 5 de 6 frases correctas; el sarcasmo (en rojo) falló con 0.846 de confianza.

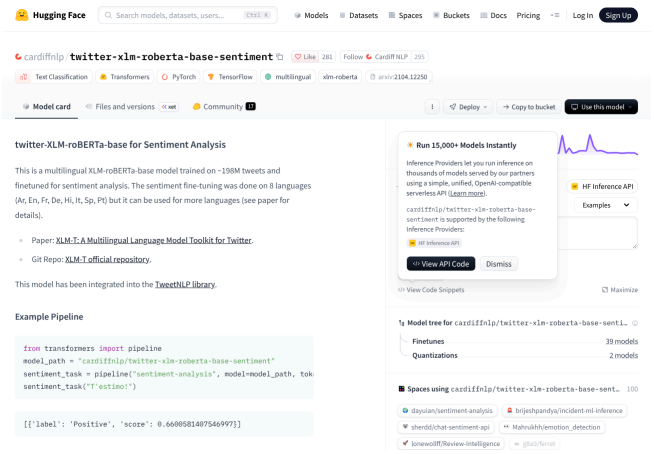
3. Mapa de competencias

Autoevaluación con tres niveles: **básico**, **en desarrollo** y **logrado**. Procuré ser exigente: marqué "logrado" solo donde puedo explicar y repetir el trabajo.

Competencia	Nivel	Evidencia	Lo que me falta
Buscar	**Logrado**	Formulé el 8-puzzle y un laberinto como espacio de estados (estados, acciones, costo, test de objetivo), implementé BFS, UCS y A*, y diseñé una heurística admisible. Medí el efecto: A* expandió 906 nodos frente a 115 310 de BFS con la misma solución óptima.	Probar otras heurísticas más informadas y búsqueda local o de adversarios a mayor escala.
Clasificar	**En desarrollo**	Entrené un clasificador Gato vs Perro en Teachable Machine (10/10 en fotos nuevas) y tres clasificadores en scikit-learn (regresión logística 0.986, kNN 0.979, árbol 0.944). Entiendo la diferencia entre transfer learning y entrenar desde cero.	Casi todo lo hice con librerías o herramientas. Aún no implemento un clasificador desde cero ni entiendo a fondo cómo aprende una red neuronal.
Evaluar	**En desarrollo**	Uso validación cruzada, matriz de confusión, ROC/AUC y separo entrenamiento y prueba. Detecté overfitting en el árbol (100 % vs 92 %) y desconfié de las métricas de Teachable Machine por tener solo 6 fotos de validación por clase.	Mis conjuntos de prueba son pequeños. Me falta aplicar intervalos de confianza, métricas por subgrupo y pruebas sobre datos de otro origen.
Razonar éticamente	**En desarrollo**	Identifiqué un fallo real con consecuencias: el modelo de sentimiento tomó un comentario sarcástico como positivo con 0.846 de confianza, y expliqué cómo eso afectaría a una moderación o a una encuesta de satisfacción. Propuse mitigaciones (leer la Model Card, probar casos difíciles, revisión humana).	Mi análisis es cualitativo. No he medido sesgo con métricas de equidad ni he trabajado con datos sobre personas.



Evidencia: predicción de Teachable Machine sobre una foto nueva (Perro, 100 %).



Evidencia: lectura de la Model Card antes de usar el modelo de Hugging Face.

4. Próximos pasos

Con lo que vi, las tres áreas que más quiero profundizar son las que hoy me dejan con más preguntas que respuestas.

Área	Qué quiero lograr	Recursos concretos
1. Machine learning clásico bien hecho (Clasificar y Evaluar)	Pasar de usar librerías a entender qué hacen: implementar regresión logística y un árbol de decisión desde cero con NumPy, y evaluarlos con validación cruzada y métricas por clase.	Curso *Machine Learning Specialization* (Andrew Ng, Coursera). Libro *Hands-On Machine Learning* (Aurélien Géron), capítulos 1 a 7. Un proyecto en Kaggle con datos tabulares.
2. Deep learning y NLP (Clasificar)	Entender cómo aprende una red neuronal y poder hacer un *fine-tuning* propio. Probar un modelo de lenguaje en español con mi propio conjunto de frases.	Curso *Practical Deep Learning for Coders* (fast.ai). Curso *LLM / NLP* de Hugging Face (gratuito). Proyecto: hacer *fine-tuning* de un modelo de sentimiento con frases colombianas y medir si corrige el fallo del sarcasmo.
3. IA responsable (Razonar éticamente)	Pasar de la intuición a la medición: calcular métricas de equidad por subgrupo y documentar un modelo con una Model Card propia.	Libro *Fairness and Machine Learning* (Barocas, Hardt y Narayanan; gratuito en línea). Artículo *Model Cards for Model Reporting* (Mitchell et al., 2019). Proyecto: auditar con métricas por grupo el clasificador de este portafolio.

Plan realista para los próximos meses

Plazo	Meta verificable
Primer mes	Terminar las primeras semanas del curso de Andrew Ng y reimplementar regresión logística desde cero, comparando su resultado con el de scikit-learn.
Meses 2 y 3	Hacer el *fine-tuning* del modelo de sentimiento con un conjunto propio de 200 frases etiquetadas y publicar la Model Card en Hugging Face.
Mes 4	Auditar un modelo con métricas por subgrupo y escribir un informe corto de hallazgos. Dejarlo todo en un repositorio de portafolio.

Mi principal riesgo es querer abarcar demasiado. Por eso fijé una sola meta verificable por mes y priorizo entender cada técnica a fondo antes de usarla como caja negra.