Portafolio de Competencias en IA

Certificación · Corte 3 · Principios de Inteligencia Artificial 2026-B (Grupo V)

Estudiante	Andrés Felipe Bolívar Arias
Programa	Ingeniería en Inteligencia Artificial - CORHUILA
Repositorio (fork)	github.com/anfebolivar2-lab/principios-ia-2026-b-g1
Entrega	Individual · Semana 5 del Corte 3 · Valor 5.0

Contenido

1. Reflexión de aprendizaje 2. Los 3 mejores artefactos 3. Mapa de competencias 4. Próximos pasos Anexo: cómo reproducir la evidencia.

Toda la evidencia (código, tablas y capturas) proviene de los archivos del repositorio y de ejecuciones reales hechas al preparar este documento; las rutas se indican en cada sección.

1. Reflexión de aprendizaje

El concepto más difícil: que una heurística "buena" tiene que ser *admisible*. Al implementar A* para el 8-puzzle (semana 4) lo difícil no fue escribir la cola de prioridad, sino entender *por qué* la distancia Manhattan garantiza una solución óptima: nunca sobreestima, porque cada movimiento desplaza una sola ficha una casilla. Me costó distinguir "encuentra una solución" de "encuentra la mejor"; una heurística que sobreestima haría a A* rápido pero potencialmente incorrecto. Otro detalle que me confundió al inicio: mis instancias "de 24 movimientos" se resolvieron en 20, porque la mezcla aleatoria incluía movimientos que se deshacían entre sí; el número de movimientos de la mezcla es solo una cota superior de la dificultad real.

El concepto más revelador: la exactitud no es lo mismo que lo correcto. En el parcial del Corte 3 el modelo de cáncer de mama alcanzó Accuracy y F1 de 0.98, y mi primera reacción fue dar el trabajo por terminado. Pero la matriz de confusión muestra **1 falso negativo**: un tumor maligno clasificado como benigno. En ese contexto un falso negativo retrasa un tratamiento, así que un solo error no pesa lo mismo que un falso positivo. Lo mismo aprendí con el ejercicio de práctica (aprobar/reprobar): con accuracy de 0.82 el modelo puede penalizar a quien trabaja mientras estudia, y una predicción de "reprobará" puede volverse una profecía autocumplida. Ahí entendí que la ética no es un apartado final: cambia qué métrica miro y para qué uso el modelo.

Cómo cambió mi visión de la IA. Antes la veía como "un modelo que predice". Ahora la veo como una cadena: formular bien el problema (estados, acciones, costo; datos, variable objetivo), elegir un método con sus garantías (completitud y optimalidad en búsqueda; validación cruzada y métricas por clase en ML), medir con honestidad y declarar los límites (datos sesgados, poblaciones distintas, decisión final humana). También cambió mi forma de trabajar: reproducibilidad (semillas fijas, `requirements.txt`, resultados regenerables con un script) y documentar las decisiones, no solo entregar código que corre.

Una autocrítica. En el Corte 1 comparé los algoritmos con una sola medición de tiempo por instancia y solo cuatro instancias; las proporciones son representativas, pero los tiempos absolutos no son estadísticamente sólidos. En el Corte 3 mis datos de práctica eran sintéticos, así que sirven para demostrar el flujo, no para sacar conclusiones sobre estudiantes reales.

Nota: este texto es un borrador redactado a partir de la evidencia del repositorio; ajusta las vivencias personales (qué se te dificultó y cómo lo resolviste) con tus propias palabras antes de entregar.

2. Los 3 mejores artefactos del semestre

Seleccioné un artefacto por corte, buscando que cada uno muestre un tipo de competencia distinto: *buscar* (Corte 1), *aprender de datos* (Corte 2) y *integrar y razonar éticamente* (Corte 3).

Artefacto 1 · Corte 1 - A* vs BFS vs UCS en el 8-puzzle

Ruta: `04-week/03-optional-activity/semana4-busqueda-informada/` (`puzzle8.py`, `compare.py`, `results.md`). Complemento: agente de laberinto BFS/A* en `05-week/03-optional-activity/maze_agent.py`.

Por qué lo elegí: es el trabajo donde mejor se ve el método científico: formulé el espacio de estados completo (estado, acciones, transición, costo, test de objetivo), verifiqué la solubilidad por paridad de inversiones, implementé tres algoritmos con la misma interfaz y los comparé con métricas objetivas (nodos expandidos, frontera máxima, tiempo). El resultado confirma la teoría: los tres hallan la solución óptima, pero A* expande muchísimos menos nodos.

```
def manhattan_distance(state, goal_pos=_GOAL_POS):
    total = 0
    for index, value in enumerate(state):
        if value == 0:
            continue
        r, c = divmod(index, 3)
        gr, gc = goal_pos[value]
        total += abs(r - gr) + abs(c - gc)
    return total          # admisible y consistente -> A* es optimo
```

Instancia	Algoritmo	Movs. (óptimo)	Nodos expandidos	Frontera máx.	Tiempo (s)
Fácil	BFS / UCS / A*	8	149 / 260 / **8**	112 / 146 / 8	0.0011 / 0.0010 / 0.0001
Media	BFS / UCS / A*	15	4 981 / 8 108 / **197**	3 128 / 4 129 / 125	0.0147 / 0.0347 / 0.0015
Difícil	BFS / UCS / A*	20	27 041 / 37 992 / **154**	10 952 / 17 023 / 93	0.0885 / 0.2276 / 0.0011
Muy difícil	BFS / UCS / A*	24	115 310 / 139 315 / **906**	24 005 / 24 053 / 515	0.5019 / 0.9788 / 0.0099

Fuente: `results.md` (salida de `compare.py`). Promedio de nodos expandidos: BFS 36 870 · UCS 46 419 · A* 316 (más de 100 veces menos).

Artefacto 2 · Corte 2 - Clasificación de tumores y overfitting

Ruta: `08-week/proyecto-ml-cancer/` (`clasificacion_cancer.py`, `resultados.md`, `figuras/`).

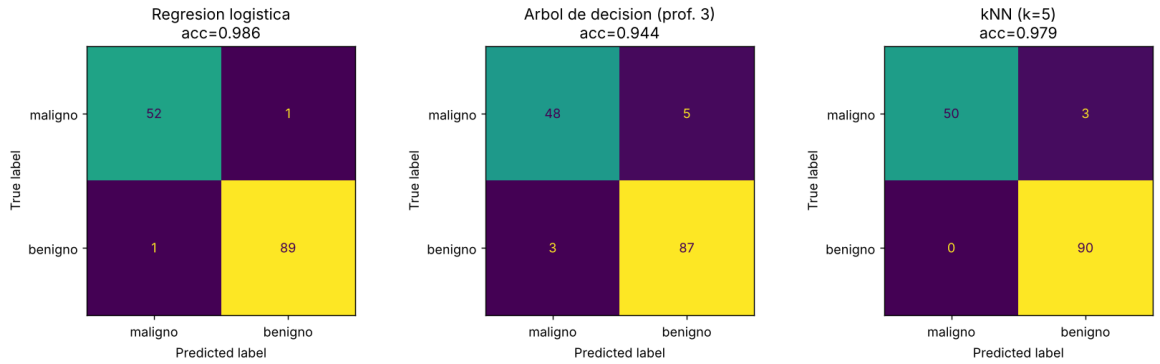
Transparencia
Mi fork no tenía un trabajo propio del Corte 2 en Git, así que este mini-proyecto fue **construido con ayuda de una IA (Claude)** durante la preparación del portafolio y está declarado así en su README. Lo incluyo porque cubre los temas del Corte 2 y se puede reproducir (lo ejecuté de nuevo y los resultados fueron idénticos), pero **no lo presento como una entrega original de ese corte**. Si tengo un trabajo propio del Corte 2, es el que debe ir aquí.

Por qué lo elegí: reúne en un solo experimento los conceptos del Corte 2: tres familias de modelos (regresión logística, árbol de decisión y kNN), validación cruzada estratificada de 5 particiones, matriz de confusión, curva ROC/AUC y una demostración de *overfitting* variando la profundidad del árbol. Además prepara el terreno para el parcial del Corte 3, que reutiliza la misma idea de comparar modelos y mirar el tipo de error.

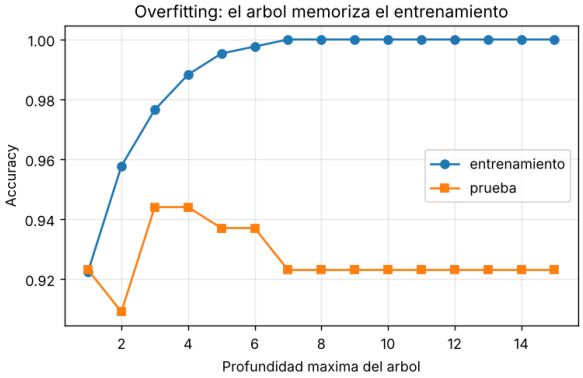
```
modelos = {
    "Regresion logistica": make_pipeline(StandardScaler(), LogisticRegression(max_iter=1000)),
    "Arbol de decision (prof. 3)": DecisionTreeClassifier(max_depth=3, random_state=SEED),
    "kNN (k=5)": make_pipeline(StandardScaler(), KNeighborsClassifier(n_neighbors=5)),
}
cv = StratifiedKFold(n_splits=5, shuffle=True, random_state=SEED)
cvs = cross_val_score(m, X_tr, y_tr, cv=cv)          # validacion cruzada
auc = roc_auc_score(y_te, m.predict_proba(X_te)[:, 1])
```

Modelo	CV 5-fold	Accuracy test	AUC test
Regresión logística	0.979 ± 0.009	0.986	**0.998**
Árbol de decisión (prof. 3)	0.939 ± 0.022	0.944	0.946
kNN (k=5)	0.967 ± 0.014	0.979	0.984

Datos: Breast Cancer Wisconsin, 569 casos (426 entrenamiento, 143 prueba; 212 malignos y 357 benignos). Fuente: `08-week/proyecto-ml-cancer/resultados.md`.



Captura: matrices de confusión de los tres modelos en el conjunto de prueba.



Captura: el árbol llega a 100 % en entrenamiento desde la profundidad 8 pero baja a 92 % en prueba (overfitting).

Lectura: el modelo lineal fue el mejor y el más simple. La regresión logística cometió 1 falso negativo (maligno clasificado como benigno) en 143 casos; en diagnóstico ese es el error más costoso, por lo que mirar solo la exactitud no basta. Esta idea la retomo en el Artefacto 3.

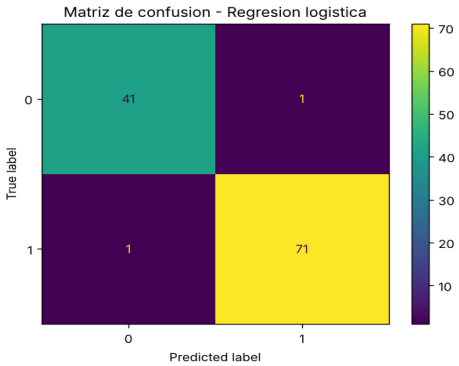
Artefacto 3 · Corte 3 - Clasificación end-to-end con limitación ética

Ruta: `15-week/parcial-practico/` (`parcial.py`, `parcial_colab.ipynb`, `practica/`).

Por qué lo elegí: integra todo el flujo: limpieza (duplicados, nulos, one-hot), partición 80/20 estratificada, dos modelos comparados con validación cruzada de 5 folds, evaluación (Accuracy, F1, matriz de confusión, reporte por clase), persistencia del modelo y una limitación ética explícita. Además lo hice reutilizable: acepta cualquier CSV (`--csv --target`) y una ética propia (`--etica`), y lo probé con un segundo problema (estudiantes) para verificar que no estuviera atado al dataset original.

```
modelos = {
    "Regresion logistica": make_pipeline(StandardScaler(), LogisticRegression(max_iter=1000)),
    "Random Forest": RandomForestClassifier(n_estimators=200, random_state=42),
}
for nombre, m in modelos.items():
    m.fit(X_tr, y_tr)
    cv = cross_val_score(m, X_tr, y_tr, cv=5, scoring="f1_weighted").mean()
    ...
mejor = max(resultados, key=lambda k: resultados[k][0])   # se elige por F1
```

```
$ python parcial.py            # Breast Cancer Wisconsin: 569 filas, 30 variables
Regresion logistica: CV-F1=0.980 | test Accuracy=0.982 | test F1=0.982
Random Forest:       CV-F1=0.960 | test Accuracy=0.956 | test F1=0.956
=== Mejor modelo: Regresion logistica ===   Accuracy: 0.9825   F1: 0.9825
Matriz de confusion: [[41  1]
                      [ 1 71]]
```



Captura: matriz de confusión generada por `parcial.py` (`salida/matriz_confusion.png`). Un falso negativo (maligno predicho como benigno).

Limitación ética declarada (del propio script): los falsos negativos retrasan un tratamiento y son más graves que un falso positivo, por lo que accuracy alta no basta; el dataset es pequeño y de una población concreta (sesgo de datos); y el modelo debe apoyar, no reemplazar, el criterio médico.

Práctica con datos sintéticos (estudiantes aprueba/reprueba): CV-F1 = 0.811, Accuracy test = 0.817 con regresión logística. Su limitación ética (profecía autocumplida, sesgo por la variable "trabaja") está en `practica/etica.txt`.

3. Mapa de competencias

Autoevaluación contra las cuatro competencias del sílabo. Niveles: **básico** · **en desarrollo** · **logrado**. Procuré calificarme con las mismas exigencias que usaría un evaluador externo.

Competencia	Nivel	Evidencia	Qué me falta
Buscar (algoritmos de búsqueda)	**Logrado**	8-puzzle con BFS, UCS y A*: formulación completa, heurística Manhattan admisible, test de solubilidad y comparación experimental en 4 instancias (`04-week/.../results.md`). Agente de laberinto BFS/A* (`05-week/.../maze_agent.py`).	Probar heurísticas alternativas y búsqueda local/metaheurísticas (hill climbing, genéticos); repetir tiempos varias veces.
Clasificar (modelos de ML)	**Logrado** (flujo) / en desarrollo (profundidad)	Pipeline completo con regresión logística y Random Forest, CV de 5 folds, split estratificado (`15-week/parcial-practico/parcial.py`); reutilizado en un segundo problema.	Afinación de hiperparámetros, desbalance de clases, redes neuronales (no tengo evidencia propia de deep learning).
Evaluar (métricas y validación)	**En desarrollo**	Accuracy, F1 ponderado, matriz de confusión y reporte por clase; comparé modelos por F1 y no solo por accuracy (Artefacto 3). En el Artefacto 2 (hecho con apoyo de IA) practiqué validación cruzada, curva ROC/AUC y detección de overfitting.	Curvas ROC/PR, intervalos de confianza, evaluación por subgrupos y elegir la métrica según el costo del error (p. ej. sensibilidad en salud).
Razonar éticamente	**En desarrollo**	Limitaciones éticas escritas para dos problemas (salud y educación): falsos negativos, sesgo de datos, profecía autocumplida, decisión final humana (`practica/etica.txt`).	Pasar del texto a la práctica: medir equidad por grupo, usar datos reales con consentimiento, auditar y documentar el modelo (model cards).

Lectura global. Mi punto fuerte es plantear y comparar métodos con rigor en problemas bien definidos. Mi mayor brecha es llevar la evaluación y la ética de la descripción a la medición (equidad, subgrupos, datos reales). No califico "logrado" en ética porque hoy identifico los riesgos pero todavía no los cuantifico.

4. Próximos pasos

Priorizo tres áreas que salen directamente de las brechas del mapa de competencias, con acciones concretas y plazos realistas para compaginar con mis demás materias.

Área	Objetivo medible	Recursos	Plazo
Evaluación de modelos y equidad	Repetir el parcial añadiendo curvas ROC/PR, sensibilidad por clase y métricas por subgrupo; publicar el resultado en el repo.	Curso *Machine Learning* (Andrew Ng, Coursera/Stanford); documentación de scikit-learn (Model evaluation); libro *Fairness and Machine Learning* (Barocas, Hardt, Narayanan, gratuito en línea).	6 semanas
Redes neuronales / deep learning	Entrenar una CNN pequeña en un dataset público y compararla con mi baseline de regresión logística.	Curso *Deep Learning Specialization* (DeepLearning.AI); tutoriales de PyTorch o Keras; *Dive into Deep Learning* (d2l.ai).	10 semanas
Búsqueda avanzada y razonamiento	Implementar hill climbing / algoritmo genético y minimax con poda alfa-beta y comparar con A*.	*Artificial Intelligence: A Modern Approach* (Russell y Norvig), caps. 3-6; ejercicios del repositorio de código del libro.	8 semanas
IA responsable en la práctica	Escribir una *model card* para el modelo del parcial y un análisis de riesgos con datos reales.	Guías de IA responsable (p. ej. Google PAIR, Model Cards for Model Reporting); normativa local de protección de datos personales.	4 semanas

Hábitos que mantendré: seguir versionando cada entrega en Git con un README que explique el problema, el método y los resultados; fijar semillas y listar dependencias para que cualquiera reproduzca mi trabajo; y construir al menos un proyecto personal por periodo que combine búsqueda o aprendizaje con un análisis ético explícito.

Anexo · Cómo reproducir la evidencia

```
# Corte 1
cd 04-week/03-optional-activity/semana4-busqueda-informada && python3 compare.py

# Corte 3
cd 15-week/parcial-practico && pip install -r requirements.txt && python parcial.py
cd practica && python ../parcial.py --csv estudiantes.csv --target aprobo --etica etica.txt

# Regenerar este PDF
pip install reportlab && python 15-week/portafolio/build_portafolio.py
```